


CLASSIFICADOR DE ACIDENTES PRF

25/06/2026 - André F. Mireski

Apresentação Final - Ciência de Dados





Motivação

- O Brasil possui um elevado número de acidentes anuais
- Foram mais de 72 mil em 2025, com mais de 6 mil mortes - Fonte CNN
- Um modelo que aprenda a classificar os acidentes com base em seu contexto (clima, período, pista) ajuda os poderes competentes a priorizar rodovias e a direcionar ações preventivas, de atendimento e de mitigação.



Perguntas de pesquisa

Como fatores climáticos influenciam nas fatalidades dos acidentes em rodovias federais?

Como fatores temporais, como proximidade com feriados, fins de semana, influenciam nas fatalidades dos acidentes em rodovias federais?



Conjunto de Dados

- **Sinistros da PRF**
- Possui dados desde 2007
- Período da análise: 2024 e 2025
- 145685 sinistros
- 30 colunas originais
- Adição de informações de **precipitação** no momento do sinistro
- Marcação de **período**: fim de semana, feriado, feriado prolongado.



Integração com o INMET

- Adição da coluna de precipitação
- Obtenção dos registros de diversas estações meteorológicas do país todo.
 - Registro hora a hora com diversas informações, como precipitação
- Descartar todas as estações que tivessem menos de 20% dos registros anuais preenchidos.
- Para cada acidente, mapear sua estação mais próxima.
- Obter para o acidente a medição da estação na hora do acidente.
- Se por ventura não houvesse leitura, preenchia com zero



Integração lib holidays

- Biblioteca **holidays**
- Mapeia os feriados mais comuns dos países
- Utilizada para criar as colunas:
 - **e_feriado** se o acidente caiu no dia do feriado
 - **em_feriado_prolongado** se caiu em um dia adjacente ao feriado (Segunda, Terça, Quinta, Sexta, Sábado de Semana)
- Feriados regionais, municipais, alguns dias santos ficam de fora, mas, os principais são cobertos.



Principais colunas

41 Colunas no total


- **horario**
- fase_dia
- **condicao_meteorológica**
- **mortos**
- **feridos**
- dia_semana
- **data_inversa**
- pessoas
- **teve_mortos (T)**
- **teve_feridos+**
- **e_fim_de_semana+**
- **precipitacao_momento+**
- **e_feriado+**
- br
- causa_acidente
- ~~**classificacao_acidente**~~
- **veiculos**
- **latitude, longitude**

Distribuição dos dados - mortos


- Amostras de 10% da população
- Poucas mortes para o volume de dados


Desvio Padrão vs. Erro Padrão - Mortos

Desvio Padrão: Dispersão dos Dados



Erro Padrão: Dispersão das Médias








Testes de Hipótese

- **T1: A presença de fatores climáticos no momento do acidente aumenta a quantidade de fatalidades.**
 - **H0:** A presença de fatores climáticos no momento do acidente, como chuvas e neblina, NÃO aumenta a quantidade de fatalidades.
 - **H1:** A presença de fatores climáticos no momento do acidente, como chuvas e neblina, aumenta a quantidade de fatalidades.
- **Teste ANOVA**

T1 - NÃO REJEITA H0





Testes de Hipótese

- **T3: Feriados, normais e prolongados, contribuem para o aumento da quantidade de fatalidades em acidentes, quando comparados a dias da semana e fins de semana sem feriados**
 - **H0:** Feriados, normais e prolongados, NÃO contribuem para o aumento de acidentes na fatalidade do número de acidentes, quando comparados a dias da semana e fins de semana sem feriados
 - **H1:** Feriados, normais e prolongados, contribuinte para o aumento de acidentes na fatalidade do número de acidentes, quando comparados a dias da semana e fins de semana sem feriados
- **Teste ANOVA**

T3 - NÃO REJEITA H0





Classificação

- **5 Experimentos:**
 - **Baseline** - Coluna de precipitação
 - **Períodos** - Colunas Baseline + colunas feriados e fins de semana
 - **Gravidade I** - Colunas Período + feridos booleanas
 - **Gravidade II** - Colunas Período + feridos quantitativa
 - **Gravidade III** - Colunas Período + combinação colunas feridos
- Colunas de id, classificacao do acidente, delegacia, número de mortos, dentre outras de menor relevância ignoradas.



Classificação


- **Modelos:**
 - **Random Forest**
 - **Linear SVM**
 - Altamente otimizado
 - **SGD (Gradiente Descendente Estocástico)**
 - Altamente otimizado
 - Comportamento: Regressor Linear ou SVM
- **Validação Cruzada em K=5 partições**
- **Tunagem com uso dos melhores parâmetros**
- **Remoção com dropna: 152**




Classificação

- **Métricas:**
 - Accuracy
 - **Precision**
 - **Recall**
 - **F1-Score**
- **Objetivo:** Modelo que acerte com confiança a classificação do acidente para guiar intervenções.


Comparação de F1 Macro por Experimento e Modelo




Precision da Classe com_mortes por Experimento e Modelo




Recall da Classe com_mortes por Experimento e Modelo




Comparação do Melhor Modelo por Experimento





Resultados

- Novas colunas não proporcionaram os ganhos desejados
 - Precision muito baixa
 - Recall baixo
- O que fez diferença foram indicativos de gravidade do acidente
 - Aumentaram a separabilidade linear dos dados
 - Modelos como **SGD (Comportamento SVM)** e o **LSVM** se saíram melhor, pois se beneficiaram dessa propriedade
- Random Forest provavelmente sofreu overfitting
- Classificação comprova os testes de hipótese




Melhorias Possíveis

- **Buscar um melhor contexto**
 - Média móvel de 7 dias de mortos, feridos, acidentes
 - Integrar com o IBGE
 - Regionalizar os dados em “distritos”
 - Fluxo ou Frota de veículos no período do acidente
 - Reduzir o número de colunas dos experimentos para tentar melhorar o Random Forest



Respondendo as perguntas

Para esse problema, nesse conjunto de dados, fatores climáticos, presença de feriados e fins de semana, não possuem qualquer efeito sobre o aumento do número de fatalidades em acidentes.

A series of approximately 10-12 thin, parallel red lines radiate from the top right corner of the image, extending diagonally towards the center.

Obrigado

Referências

- Sinistros PRF
- Repositório
- Dados do Inmet
- Matéria CNN