

André Felipe Mireski

Trabalho Final Ciência de Dados Entrega 05

Última entrega do trabalho final, solicitada pelo professor Eduardo Pena na disciplina de Ciência de Dados do Bacharelado em Ciência da Computação da Universidade Tecnológica Federal do Paraná

Universidade Tecnológica Federal do Paraná – UTFPR

Departamento Acadêmico de Computação – DACOM

Bacharelado em Ciência da Computação – BCC

Campo Mourão

Maio / 2026

Sumário

1	Resumo	3
2	Escolha e Definição do Problema	3
3	Metodologia	4
3.1	Pré-processamento dos dados	4
3.2	Análise dos dados	6
3.3	Avaliação da classificação	7
4	Resultados	7
4.1	Testes de hipótese	7
4.2	Classificação	9
5	Trabalhos Futuros	10
	Referências	10

1 Resumo

Nesse trabalho foi criado um classificador de acidentes fatais nas rodovias federais brasileiras que tinha como intuito, utilizar atributos de contexto do acidente, como precipitação do momento, presença de feriados, fins de semana, condições climáticas, de pista, dentre outras características, para treinar modelos LSVM, SGD e Random Forest, com o intuito de identificar com esse contexto padrões que ajudassem na classificação e que direcionassem os órgãos competentes para tomarem ações de mitigação. Porém, os testes estatísticos de hipótese, as análises dos dados e resultados dos classificadores demonstraram que, com exceção de atributos relacionados à presença e quantidade de feridos, o conjunto de dados não apresentou nenhum outro tipo de atributo que fornecesse um contexto mais discriminativo para a separação entre as classes do problema, acabando por favorecer modelos que dependiam fortemente de uma boa separabilidade linear dos dados, como o LSVM e SGD, que foram os melhores.

2 Escolha e Definição do Problema

O dataset que escolhi é o [SINISTROS DE TRÂNSITO - PRF](#), um dataset que contém “Dados de sinistros de trânsito, registrados pela Polícia Rodoviária Federal, com dados desde “01/01/2007”.

O escopo do trabalho foca em analisar os dados das ocorrências dos anos de 2024 e 2025. Nesse período, segundo a análise dos dados, antes do pré-processamento, o dataset conta com:

- 145685 registros
- 30 colunas base, com a seguinte distribuição de tipos:
 - booleano: 1
 - data/hora: 1
 - numérico: 10
 - texto: 18

Esses números atendem aos requisitos mínimos de linhas e colunas e o dataset, por contar com a coordenada do local do acidente, torna possível a integração externa com dados [meteorológicos do INMET](#), que permitem obter informações mais detalhadas acerca do tempo, segundo a estação mais próxima daquele local. A linha de abordagem deste trabalho será guiada pelas seguintes perguntas: “**Como fatores climáticos influenciam nas fatalidades dos acidentes em rodovias federais?**” e “**Como fatores temporais, como proximidade com feriados, fins de semana, influenciam nas fatalidades dos acidentes em rodovias federais?**”.

O objetivo é treinar um classificador para identificar padrões com base no contexto do acidente, como fatores climáticos e período (feriados, feriados prolongados, fim de semana), principalmente naqueles em que ocorreram fatalidades. Esse modelo poderia ser utilizado para

analisar as ocorrências e gerar um panorama geral de quais rodovias estão em situação mais crítica, apresentando mais fatalidades por conta dos fatores climáticos, o que ajudaria a direcionar serviços de alerta e prevenção de acidentes, a fim de indicar quais estradas precisariam de mais atenção do poder público a fim de tentar mitigar esses acidentes.

As hipóteses iniciais deste trabalho foram as seguintes:

- T_1 : *A presença de fatores climáticos no momento do acidente aumenta a quantidade de fatalidades*
- T_2 : *Fatores climáticos contribuem mais para o aumento de fatalidades em acidentes do que outros fatores, tais como, época do ano e fins de semana*
- T_3 : *Feriados, normais e prolongados, contribuem para o aumento da quantidade de fatalidades em acidentes, quando comparados a dias da semana e fins de semana sem feriados*

A motivação por trás da escolha desse problema é o fato do Brasil, como aponta [matéria da CNN](#), possuir um elevado número de acidentes anuais, com número considerável de fatalidades. Então, um modelo que aprendesse a classificar a gravidade de acidentes com base no seu contexto, como pista, fatores climáticos, período, dentre outros, poderia auxiliar os poderes competentes a gerenciar e direcionar melhor os esforços de mitigação, priorizando certas rodovias, distribuindo melhor serviços de atendimento, dentre outras medidas que podem ser adotadas.

3 Metodologia

Nessa sessão são descritos os tratamentos realizados no conjunto de dados, as fontes externas que foram integradas, análises dos dados e como se dará o processo de classificação.

3.1 Pré-processamento dos dados

Originalmente, o conjunto de dados de sinistros contava com colunas quantitativas que diziam, entre outras informações, quantos mortos e feridos ocorreram no acidente. O objetivo do modelo é classificar os acidentes entre as classes: *Acidente fatal* e *Acidente não fatal*. Então, foi criada uma coluna booleana *teve_mortos* para ser o indicativo de classe dos dados. Como, dependendo do classificador, a informação de presença ou não de feridos, feridos leves e graves também poderia ser útil, eliminando a necessidade de utilizar as colunas quantitativas, foram criadas outras colunas booleanas: *teve_feridos*, *teve_feridos_leves*, *teve_feridos_graves*, *teve_ilesos*.

Uma das perguntas insinua uma comparação entre fatores climáticos e períodos ao longo do ano, como fins de semana, feriados prolongados e feriados. Então, foi criada uma outra coluna booleana, *e_fim_de_semana*, para indicar que o acidente ocorreu no Sábado ou no Domingo.

Para os feriados, foi utilizada a biblioteca *holidays* que carregou os feriados brasileiros nos anos de 2024 e 2025 e utilizou essas informações para, caso o acidente tivesse ocorrido num

dia de feriado, marcar a coluna booleana *e_feriado*. Já a coluna *em_feriado_prolongado* era marcada sempre que era detectado um feriado que podia ser prolongado com o fim de semana. A limitação dessa biblioteca é que ela captura os feriados principais, mas, feriados locais, como padroeiro da cidade, aniversário do município, dias santos, não são detectados em sua totalidade, o que faz com que os valores dessa coluna não sejam completamente fiéis à realidade.

Além dessas colunas, foram realizadas integrações com dados do INMET (Instituto Nacional de Meteorologia), para obter as informações de precipitação no momento do acidente, já que uma das hipóteses é de que fatores climáticos, chuva inclusive, podem contribuir para o aumento na fatalidade dos acidentes.

Os pormenores da integração com o INMET estão descritos no notebook, mas, em resumo, para cada acidente, foi descoberta a estação meteorológica mais próxima e obtida a precipitação que a estação reportava na hora do acidente.

Todavia, essa integração possui algumas limitações. Não era garantido que a estação estivesse funcionando no momento do acidente. Como também não era garantido que o valor da precipitação correspondesse exatamente à situação no local do acidente, pois pode ser que, mesmo com poucos quilômetros de distância, na estação esteja chovendo e na pista não, e vice-versa.

Dados de precipitação faltantes por conta do não funcionamento das estações foram um problema, com estações que ficaram inoperantes por mais de 80% do período de análise, sendo descartadas. Na ausência de dados de precipitação, a nova coluna de precipitação foi preenchida com zeros. Uma abordagem possível que talvez fosse mais assertiva para se lidar com os valores faltantes seria, ao invés de olhar somente a estação mais próxima do acidente, olhar para as três mais próximas e pegar o primeiro valor de precipitação preenchido.

Ao final do pré-processamento e da integração com fontes externas, a configuração do conjunto de dados passou a ser:

- 145685 registros
- 41 colunas, com a seguinte distribuição de tipos:
 - booleano: 10
 - data/hora: 1
 - numérico: 11
 - texto: 19

Por limitações de tempo, não foram realizadas integrações com outras fontes externas, mas, para trabalhos futuros, seria possível integrar dados do IBGE para agrupar os acidentes em micro-regiões baseadas na proximidade dos municípios, possibilitando extrair informações mais precisas acerca de fluxo de veículos nas estradas nesse período.

3.2 Análise dos dados

Após a montagem do conjunto de dados, foram realizadas algumas análises sobre esse conjunto a fim de identificar quais variáveis de contexto (precipitação, hora do dia, feridos, dentre outras) poderiam ser mais úteis para os modelos diferenciarem um acidente em que ocorreram fatalidades de um sem fatalidades.

Como mostra a Figura 1, a distribuição no número de mortes, mesmo em amostras de 10% da população, segue uma distribuição assimétrica à esquerda, com a grande maioria dos acidentes não resultando em fatalidades, como mostram as médias que ficam na casa dos 0,08 mortos por acidente. Essa concentração dos dados faz com que seja comum a presença de valores aberrantes nessa coluna.




Figura 1 – Distribuição da coluna *mortos*

Sobre a busca de variáveis que ajudassem o classificador a melhor diferenciar as classes do problema, com base no contexto do acidente, não foi encontrada nenhuma variável em particular que tivesse uma boa correlação com a coluna de *mortos*, como mostra a Figura 2.




Figura 2 – Matriz de correlação de variáveis

Relações fortes esperadas, como número de feridos, tipo de pista, fase do dia, precipitação, dentre outras, não ocorrem. A relação relevante mais fortes da variável alvo, *teve_mortos* foi com a coluna de classificação do acidente, com 0,95 de coeficiente, que se dá pelo fato de uma das classificações possíveis ser “Com Vítimas Fatais”, o que não é muito interessante para

a abordagem desse trabalho, já que praticamente entrega para o classificador qual a classe do acidente, não necessitando de nenhum outro contexto do momento do acidente, que não é o objetivo. Por esse motivo, essa coluna não foi considerada na etapa de classificação.

3.3 Avaliação da classificação

Para o experimento de classificação com Machine Learning, foram realizados cinco experimentos, em que foram variadas a quantidade de informações fornecidas para os modelos:

- **Baseline:** Possuía a coluna de precipitação, mas não contava com as colunas de feridos e de indicativo de período, como *e_feriado*.
- **Período:** Adicionadas as colunas *e_feriado*, *em_feriado_prolongado* e *e_fim_de_semana*.
- **Gravity I:** Adicionadas as colunas booleanas de feridos, sem as quantitativas.
- **Gravity II:** Adicionadas as colunas quantitativas de feridos, sem as booleanas.
- **Gravity III:** Adicionadas todas as colunas de feridos.

Os classificadores escolhidos foram o SGD (Gradiente Descendente Estocástico), o SVM Linear (LSVM) e o Random Forest. O principal critério para a escolha foram eles serem otimizados e conseguirem executar na máquina do desenvolvedor com todo o conjunto de dados.

Para avaliar os classificadores foi escolhida como métrica principal o *F1-Score* Macro, já que o número de acidentes com fatalidades é muito menor do que os sem fatalidades, e o desejável era um classificador com bom desempenho em reconhecer ambas as classes com um bom nível de certeza.

4 Resultados

Nessa sessão são apresentados os resultados dos testes de hipótese e da classificação, assim como a interpretação de seus resultados.

4.1 Testes de hipótese

Analisando a formulação das hipóteses, descritas na Seção 2, percebe-se que elas tratam da comparação entre variáveis categóricas, como condição meteorológica, presença de feriado, presença de fins de semana, e uma variável numérica, no caso, número de mortos. Por esse motivo, foram realizados testes ANOVA para validar essas hipóteses.




Figura 3 – Boxplot distribuição de mortos por condição climática

Na Figura 3, pode-se ver o *boxplot* que mostra a distribuição de mortos por condição climática, juntamente com o resultado do teste no título. Pela imagem é possível ver que, como mostrou a Figura 1, o número de mortos, independente da classe, se concentra em grande maioria, no entorno de uma única morte, com demais valores sendo aberrantes. Por conta dessa característica, não há nada, no geral, que destaque um fator climático do outro, o que contribui para um $p_1 = 0,2240$, que não rejeita H_0 da hipótese T_1 , mostrando que, para esses dados, não há uma condição climática em especial que contribua mais ou menos para a fatalidade no número de acidentes.




Figura 4 – Boxplot distribuição de mortos por fator

Já para hipóteses T_2 e T_3 , que questionam a influência de fatores como feriados e fins de semana no número de acidentes, os resultados dos testes são exibidos nas Figuras 4 e 5. Seguindo o mesmo padrão de distribuição do primeiro teste, vê-se que não há, com exceção dos valores aberrantes, nada que diferencie uma categoria da outra, o que acaba contribuindo para os resultados $p_2 = 0,5519$ e $p_3 = 0,5589$, que mostra que as hipóteses H_0 não foram rejeitadas novamente. Com esses resultados, conclui-se que fatores climáticos não se destacam mais do que feriados e fins de semana no aumento do número de fatalidades em acidentes, nem estes contribuem mais para o aumento desse número.




Figura 5 – Boxplot distribuição mortos por categoria de dia

Então, com esses testes, basicamente já é possível responder às perguntas de pesquisa. **Como fatores climáticos influenciam nas fatalidades dos acidentes em rodovias federais?**

A resposta é que, pelos testes estatísticos, prova-se que, pela natureza assimétrica da distribuição no número de mortos por acidentes, que fica na casa de uma única morte, fatores climáticos como chuva, no momento do acidente, não possuem qualquer influência no aumento do número de fatalidades quando comparados a dias de clima limpo.

Já para a pergunta: **Como fatores temporais, como proximidade com feriados, fins de semana, influenciam nas fatalidades dos acidentes em rodovias federais?** A resposta é que, pelos testes estatísticos, prova-se que, pela natureza assimétrica da distribuição no número de mortos por acidentes, que fica na casa de uma única morte, fatores como proximidade de feriados e ocorrência de fins de semana não se destacam de dias normais.

4.2 Classificação

A Figura 6 mostra a comparação entre os melhores modelos em cada experimento. Pela imagem, percebe-se que, inicialmente, apesar do F1-Macro na casa dos 65%, a capacidade do modelo em reconhecer acidentes fatais, com uma boa precisão, era bem baixa, na casa dos 28,73%, mostrando que as características fornecidas para o experimento da Baseline não eram tão discriminantes a ponto de proporcionar uma boa separabilidade linear entre os dados.




Figura 6 – Gráfico de melhores modelos

No experimento de períodos, houve uma piora nos resultados, com a precisão sendo reduzida. Com isso, reforça-se o ponto de que as colunas novas que indicam feriados e fins de semana não contribuem significativamente para a identificação de fatalidades, pelo contrário, acabam deixando a decisão do modelo mais ambígua.

A partir dos experimentos em que as colunas de gravidade (feridos, mortos e suas versões booleanas) passam a ser utilizadas, percebe-se uma melhora significativa no desempenho dos modelos, tanto no *recall* quanto na *precision*, mostrando que essas colunas proporcionam uma maior separabilidade linear entre as classes de acidentes com e sem mortes. A melhora nessa característica ajuda a explicar o porquê da LSVC ter sido o modelo que mais se destacou, já que ele depende muito dessa propriedade para funcionar adequadamente.

Análises mais detalhadas de cada um dos modelos, em cada um dos experimentos, podem ser vistas no notebook.

Nesse contexto, os resultados dos classificadores só reforçam como as características adicionadas ao conjunto de dados de precipitação, de marcação de feriados, de marcação de fins de semana, não impactam significativamente no aumento do número de fatalidades em acidentes.

5 Trabalhos Futuros

Com base em tudo que foi apresentado, conclui-se que características de contexto, como fatores climáticos, precipitação, presença ou não de feriados e fins de semana, não são tão discriminantes quanto informações acerca de feridos, para os classificadores utilizados nesse problema, não permitindo extrair informações relevantes que direcionem ações de órgãos competentes.

Para os trabalhos futuros, o objetivo seria encontrar outras características de contexto em relação ao acidente mais discriminantes do que as já tentadas nesse trabalho.

Um tipo de informação que poderia ter algum impacto, sem revelar o número exato de feridos e mortos dos acidentes de forma isolada, seria a adição de médias móveis de sete dias de mortos, feridos e de acidentes. É uma hipótese razoável de que acidentes que ocorrerem durante períodos de aumento nessas médias terão maiores chances de serem fatais. Para o cálculo, os dados poderiam ser agrupados por BR ou por sub-região, englobando vários municípios.

Outra informação útil seria o fluxo de veículos no período próximo ao acidente, ou tamanho das frotas, nessas sub-regiões, que poderiam ser obtidos cruzando informações com o IBGE e calculando a média móvel. Também é razoável pensar que quanto maior o fluxo de veículos, maior a chance de acidentes ocorrerem.